

# AMSR-E 地表温度数据无缝重建深度学习方法

## 摘要

地表温度数据 (Land Surface Temperature, LST) 是重要的气候资源之一, 对全球气候变化等研究具有重要意义。被动微波遥感传感器 (如 Advanced Microwave Scanning Radiometer for EOS, AMSR-E) 可获取全天候的地表温度数据, 但由于轨道间的扫描间隙导致数据存在部分缺失, 限制了该数据在全球或区域尺度的实际应用能力。现有的多时相特征连接卷积神经网络模型重建方法 (Multi-temporal Feature Connection-CNN, MTFC-CNN) 在样本数量较少、样本特征不够丰富时, 重建结果存在明显的“有缝”痕迹。基于此, 本文在分析 AMSR-E LST 轨道间隙的周期性和邻近时空互补性特征基础上, 提出了一种样本优化的多时相特征连接卷积神经网络无缝重建方法 (Sample Optimized MTFC, SO-MTFC), 样本优化包括小范围缺失样本对插值生成方法和单次循环掩膜策略两个方面。以中国大陆区域为研究对象, 将 AMSR-E LST 数据按照昼夜、季节划分为 10 个数据子集进行实验。结果表明: 重建区域的地表温度数值大小合理, 温度分布形状保持了相对连续性, 原始区域与重建区域基本实现无缝连接; 与相应的 MODIS LST 产品对比中发现, 重建区域 LST 值和原始区域 LST 值与 MODIS LST 产品间具有相近的均方根误差以及决定系数, 其中每月 15 日对比中, RMSE 在白天偏差 0.56 K、夜晚偏差 0.7 K,  $R^2$  白天、夜晚偏差均为 0.05; 地面站点验证实验中, 黑河流域 (Heihe River Basin, HRB) 3 个站点原始区域、重建区域 RMSE 的整体平均偏差为 0.52 K; 与原始 MTFC-CNN 方法比较中, 本文方法 SO-MTFC 取得了更好的目视效果, 且以 MODIS LST 作为参考时, 白天 RMSE 提升 0.34 K, 夜晚 RMSE 提升 0.16 K。因此本文方法能够稳健、有效地重建 AMSR-E LST 轨道间隙。

**关键词:** 遥感; 地表温度; 无缝重建; 深度学习; AMSR-E LST

# **Gapless Reconstruction for AMSR-E Land Surface Temperature Data using Deep Learning Method**

## **Abstract**

Land Surface Temperature (LST) data is one of the important climate resources and has significant implications for global climate change research. Passive microwave remote sensing sensors (such as Advanced Microwave Scanning Radiometer for EOS, AMSR-E) can obtain all-weather surface temperature data, but due to the scanning gap between orbits, there are some missing data, which limits the practical application ability of this data at global or regional scales. The existing multi temporal feature connection convolutional neural network model (MTFC-CNN) has obvious "seam" marks in the reconstruction results when the number of samples is small and the sample features are not rich enough. Based on this, this article proposes a sample optimized multi temporal feature connected convolutional neural network seamless reconstruction model (Sample Optimized MTFC, SO-MTFC) based on the analysis of the periodicity and adjacent spatiotemporal complementarity characteristics of AMSR-E LST orbital gaps. The sample optimization includes two aspects: a small range missing sample pair interpolation generation method and a single cycle mask strategy. Taking the Chinese Mainland region as the research object, the AMSR-E LST data is divided into 10 data subsets according to day, night and season for experiments. The results show that the surface temperature value in the reconstruction area is reasonable, the temperature distribution shape maintains relative continuity, and the original area and the reconstruction area basically achieve seamless connection; In comparison with the corresponding MODIS LST products, it was found that the reconstructed region LST values and the original region LST values had similar root mean square errors and determination coefficients with MODIS LST products. Among them, on the 15th of each month, RMSE had a deviation of 0.56 K during the day and 0.7 K at night, while  $R^2$  had a deviation of 0.05 during the day and night; In the ground station validation experiment, the overall average deviation of RMSE in the original and reconstructed regions of the Heihe River Basin (HRB) was 0.52 K for the three stations; Compared with the original MTFC-CNN method, the SO-MTFC method in this paper achieved better visual effects; When using MODIS LST as a reference, RMSE increased by 0.34 K during the day and 0.16 K at night. Therefore, this method can robustly and effectively reconstruct the AMSR-E LST orbital gaps.

**Keywords:** remote sensing; land surface temperature; seamless reconstruction; deep learning; AMSR-E LST

# 目 录

1 绪论 .....	1
1.1 研究背景及意义 .....	1
1.2 国内外研究现状 .....	1
1.3 技术路线 .....	2
1.4 论文的章节安排 .....	4
2 研究区域与数据 .....	4
2.1 研究区域概况 .....	4
2.2 AMSR-E LST 数据 .....	5
2.3 MODIS LST 数据 .....	5
2.4 地面站点数据 .....	5
2.5 数据预处理 .....	6
3 多时相地表温度数据样本集构建及优化 .....	6
3.1 轨道间隙时空分布特征分析 .....	7
3.2 样本最邻近插值生成方法 .....	8
3.3 单次循环模拟掩膜策略 .....	9
4 模型构建与轨道间隙重建 .....	10
4.1 深度学习网络模型构建及训练 .....	10
4.1.1 模型构建 .....	10
4.1.2 模型训练 .....	12
4.2 轨道间隙区域批量重建 .....	13
5 结果分析 .....	14
5.1 中国大陆区域重建结果 .....	14
5.2 MODIS LST 对比精度评价 .....	15
5.3 站点数据精度评价 .....	17
5.4 与原始 MTFC-CNN 结果对比 .....	18
6 总结与展望 .....	19
主要参考文献 .....	20
致 谢 .....	22

# 1 绪论

## 1.1 研究背景及意义

作为陆地-大气界面长波辐射和湍流热通量交换的直接驱动力，地表温度 LST (Land Surface Temperature, LST) 是地表辐射能量平衡和水循环物理过程中的关键参数<sup>[1-2]</sup>。快速、准确获取 LST 的时空分布对农业生产、基础建设、生态环境研究等方面具有重要意义。在获取区域性或全球性地表温度方面，常规的地面监测站难以提供空间连续的地表温度数据，适用性较差，而卫星遥感是唯一可能且最可靠的手段<sup>[3-4]</sup>。与地面站点测量相比，卫星遥感具有较好的空间覆盖能力和可接受的重返周期，提供了一种简单、有效的方法来获取大区域、长时间序列的多尺度地表温度<sup>[5]</sup>。

基于卫星的 LST 主要来源于热红外 (Thermal infrared, TIR) 遥感反演和被动微波 (Passive microwave, PMW) 遥感反演。由于其相对精细的空间分辨率和适当的精度，基于 TIR 遥感反演的地表温度引起了学者的广泛关注，并生产和免费发布了各种热红外遥感地表温度产品<sup>[6-7]</sup>。然而，TIR 传感器的主要缺陷是无法穿透云层，难以获取云覆盖区域的信息，使得 LST 时空分布的完整性和连续性受到破坏，严重阻碍了 TIR LST 产品的应用<sup>[8-9]</sup>。相比之下，被动微波 PMW 可以穿透非降水云，受大气吸收和水蒸气的影响最小<sup>[10]</sup>，并且具有可获取全天候地表辐射信息的优势<sup>[11]</sup>。例如地球观察系统中先进的微波扫描辐射计 (Advanced Microwave Scanning Radiometer for EOS, AMSR-E)，是 TIR 测量不满足需求时的重要补充或替代，尤其是在多云条件下<sup>[12]</sup>。然而，其特定扫描方式导致两个相邻轨道之间出现了扫描间隙（以下称为轨道间隙）的问题，无法提供完全的空间无缝观测，中低纬度地区数百公里的间隙严重影响了实际应用。因此，迫切需要一种有效的重建方法来填补 PMW LST 产品中的轨道间隙，故对 AMSR-E 地表温度数据无缝重建具有重要理论价值与实际意义。

## 1.2 国内外研究现状

目前遥感 LST 缺失信息的重建研究主要集中于热红外 (TIR) 缺失信息的重建，针对不同情况产生了大量创新性研究方法。重建热红外 (TIR) 云下 LST 的方法大致可以分为三大类：时间或空间插值方法<sup>[13-14]</sup>、数据融合方法<sup>[15]</sup>、统计回归方法<sup>[16]</sup>。

其中基于空间信息插值的方法只适用于小范围信息缺失，在大范围信息缺失时难以保证精度；基于时相信息插值的方法假设原始区域和缺失区域在一定时间内有相似的变化信息<sup>[17]</sup>；采用数据融合方法，需要不同传感器在相同时间获取相同区域的地物信息，因而面临时间、空间分辨率以及光谱分辨率差异的问题；统计回归方法通常使用经验、半经验函数或回归模型将无云的 TIR LST 与附加信息（例如 DEM、NDVI 等）联系起来，利用这些信息计算有云覆盖的 TIR LST。尽管附加信息可以广泛获得，但是在大面积、异质表面区域附加信息的支持性往往不够。

相比之下，PMW LST 重建方法还没有得到很好的发展。现有研究尝试用数据插值经验正交函数法(DIEOF)<sup>[12]</sup>、反向距离加权法(IDW)<sup>[18]</sup>、地理和时间加权回归模型(GTWR)<sup>[19]</sup>、

奇异谱分析算法(SSA)<sup>[20]</sup>来填补 PMW LST 的轨道间隙，一定程度上达到了可接受的重建效果。然而，由于陆地表面温度的强异质性和高动态变化特点，LST 的分布在空间和时间上是不均匀和非平稳的，传统方法在重建 PMW 温度数据较大轨道间隙时，性能不够稳定。

考虑到地表温度与环境变量高度相关性，Duan 等人提出了一种基于深度神经网络(Deep Neural Network, DNN)的轨道间隙填充方法。该方法首先基于 AMSR2 LST 与 11 个环境变量之间的非线性关系建立 DNN 模型，然后利用 DNN 模型生成新的空间连续的 LST 产品，最后对 AMSR2 LST 的轨道间隙进行填充<sup>[21]</sup>。该方法的重建效果取决于作为环境变量的辅助数据质量，仅依靠 PMW LST 自身数据难以实现轨道间隙的有效重建。

受卷积神经网络的深度学习架构强大非线性表示能力的启发，Wu 等人提出了一种多时间特征连接卷积神经网络(Multi-temporal Feature Connection-CNN, MTFC-CNN)，以重建轨道间隙区域获取空间完整的 AMSR-E LST 数据，进而与云下 MODIS 地表温度数据融合<sup>[22]</sup>。该方法不需要任何其他辅助数据，仅利用 PWM LST 即可实现轨道间隙重建。作为专门为 PWM LST 轨道间隙重建而设计的方法之一，MTFC-CNN 除了具有强大的非线性表示能力外，更有效利用了 AMSR-E LST 轨道间隙时空互补性、周期性的特点。充足且丰富的训练样本是 MTFC-CNN 性能的先决条件。然而，由于顺序裁剪操作(即从左上到右下)、较大尺寸的轨道间隙、以及轨道间隙位置随日期不断变化，导致在不同场景中获得的样本数量不同，甚至在部分场景下无法获取完整的训练样本，这一定程度上影响了重建精度。在样本数量较少、样本特征不够丰富的日期，重建结果仍存在轨道间隙的“有缝”痕迹，导致模型不能稳健地重建所有日期的轨道间隙。因此，迫切需要发展一种 AMSR-E LST 轨道间隙缺失数据的无缝重建方法。

基于原始 MTFC-CNN 方法的缺陷，并结合 AMSR-E LST 数据轨道间隙的周期性和邻近时空互补性分布特征，本文提出一种样本优化的多时相特征连接卷积神经网络模型重建方法(Sample Optimized MTFC, SO-MTFC)，对 AMSR-E LST 轨道间隙缺失数据进行无缝重建，以优化、解决上述问题。

### 1.3 技术路线

本研究的技术路线分为四个部分：AMSR-E LST 轨道间隙时空特征分析、LST 样本数据集构建及优化、多时相特征连接神经网络搭建及训练、轨道间隙区域批量重建。

本文对 AMSR-E LST 数据轨道间隙进行无缝重建的技术路线如图 1 所示。

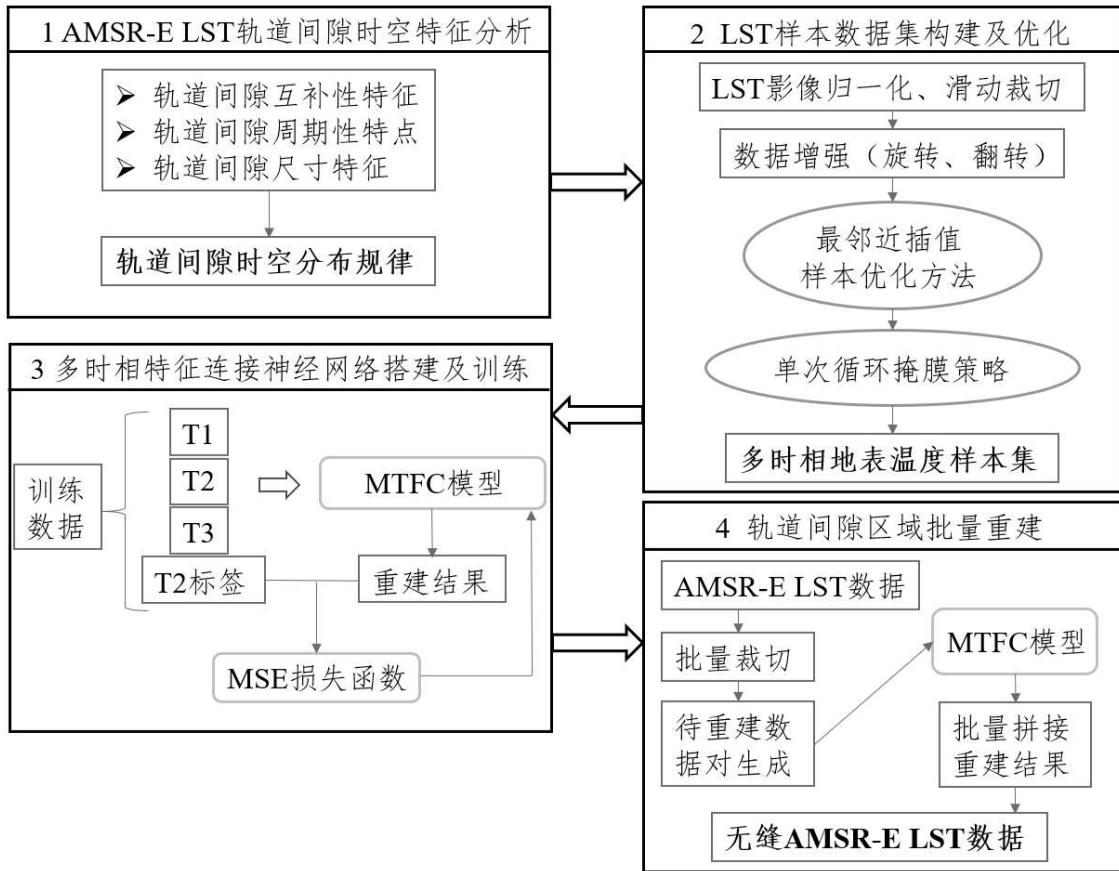


图 1：技术路线图

(1)AMSR-E LST 轨道间隙时空特征分析。对 2010 年全年 AMST-E LST 影像进行分析，重点关注轨道间隙的位置变化周期性特点，以及邻近时相轨道间隙互补性特征。对多时相影像进行批量的叠加显示、目视观察，总结出 AMSR-E LST 影像轨道间隙的变化规律，为多时相地表温度样本数据集构建提供思路。

(2)多时相地表温度样本集构建与优化。AMSR-E LST 数据像素值单位为卡尔文 (K)，为提升训练性能，进行归一化操作。为获取充足的样本数据，对 AMST-E LST 影像进行数据增强操作：轨道间隙具有固定的倾斜角度，为产生丰富位置的样本影像块，对 AMSR-E LST 影像进行一定角度的旋转；同样通过水平翻转、垂直翻转增加样本数量。采用最邻近插值样本集优化方法、单次循环模拟掩膜策略构建多时相地温数据样本库，确保样本集具有足够丰富、可供模型学习的特征。

(3)多时相特征连接神经网络搭建及训练。基于 Tensorflow2 平台，搭建 MTFC 模型，使用已获取的地表温度样本数据集进行训练。损失函数采用均方误差 MSE，优化器使用 Adam，并不断调整其他训练参数，使模型提高重建精度。

(4)轨道间隙区域批量重建。按照样本集数据对相同的生成方式，生成待重建的多时相影像块组合，使用训练好的模型进行重建。裁切过程中影像块具有重复部分，使用平均权重拼接方式拼接重建后的影像块，进而获得完整无缝的 AMSR-E LST 影像数据。

## 1.4 论文的章节安排

本论文总共分为六个章节，各章节内容安排如下：

第一章，绪论。该章节主要介绍了本论文的研究背景及研究意义，结合国内外在地表温度数据重建的研究现状进行分析，对各种方法进行分析、总结、归纳，针对现有方法的不足提出本论文的改进方法。

第二章，研究区域与数据。该章节首先介绍本次 AMSR-E LST 无缝重建研究区域的位置境域、地形地貌以及气候条件特点。其次介绍了本研究使用的 AMSR-E LST 产品的相关情况，用于参考评价的 MODIS LST 产品信息，以及地面验证站点数据。最后介绍了实验数据质量控制、重采样、配准等预处理操作。

第三章，多时相地表温度数据样本集构建及优化。首先对 AMSR-E LST 数据轨道间隙分布的时间特征、空间特征进行了分析，并以此为基础提出多时相样本的时相组合方式。详细介绍了为优化样本集提出的最邻近插值样本生成方法以及单次循环模拟掩膜策略。

第四章，模型构建与轨道间隙重建。基于 Tensorflow2 框架搭建 MTFC 模型，详细介绍了该模型的输入层、输出层以及模型的结构特点。并说明了本研究模型训练过程中使用的相关参数，如优化器设置、损失函数的选取等。最后介绍了批量重建的方法。

第五章，结果分析。以 MODIS LST 数据为参考，分别计算 AMSR-E LST 原始像素值、重建像素值与 MODIS LST 数据的 RMSE（均方根误差）和 R<sup>2</sup>（决定系数），定量评价本研究的重建结果；同样使用地面站点温度数据进行验证，并与原始 MTFC-CNN 重建结果进行对比分析。

第六章，结论与展望。总结了本文的主要研究方法及成果，指出了本研究存在的不足以及未来可提高的方向。

## 2 研究区域与数据

### 2.1 研究区域概况

图 2-a 为研究区域的边界示意图，图 2-b 为 AMSR-E LST 数据在中国大陆区域的示例图，中国大陆白色轨道区域即为缺失数据区域，图 2-c 为本研究使用的地面站点位置示意图。中国拥有面积巨大的陆地，地理环境多样。中国的气候类型表现出明显的纬度异质性和海陆异质性：(1) 从北到南为冷温带、中温带、暖温带、亚热带和热带；(2) 从东到西为季风和非季风区。中国的地形复杂多样，东部是冲积平原，北部是广阔的草原，南部是丘陵和低山，西部是主要山脉。由于气候和地形的变化，中国的 LST 分布差异较大<sup>[21]</sup>。

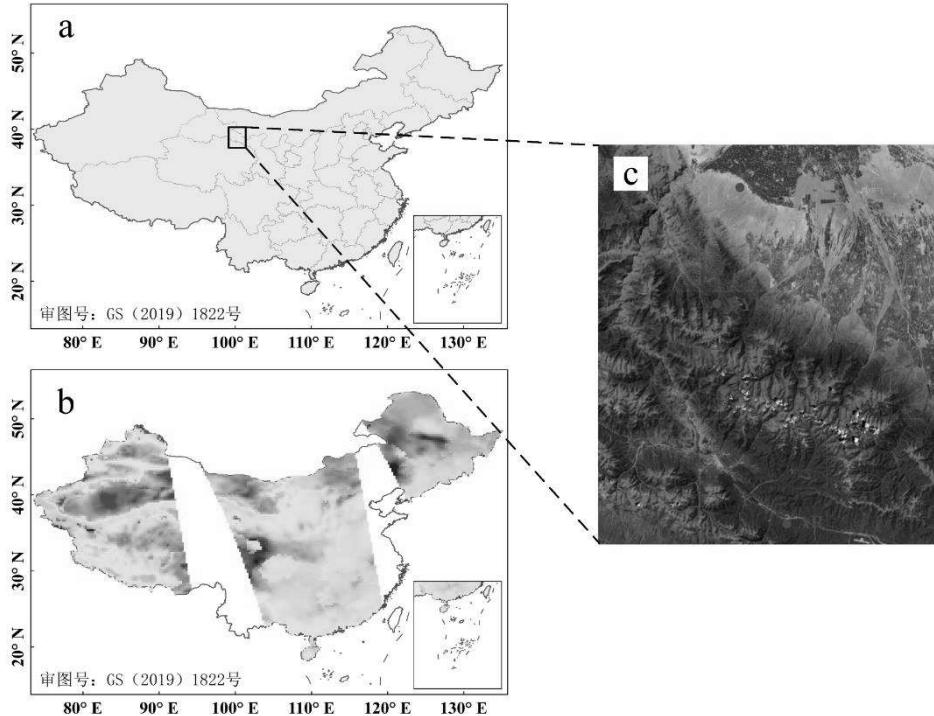


图 2：研究区域概况

(a: 中国大陆边界示意图; b: AMSR-E LST 中国大陆区域数据示意图; c: 地面验证站点分布图)

## 2.2 AMSR-E LST 数据

AMSR-E 是搭载在 Aqua 卫星上的先进微波扫描辐射仪，从 2002 年到 2011 年，在当地时间凌晨 1:30（下降）和下午 1:30（上升）观测地球。它包含 12 个信道，分布在六个频率（即 6.9 GHz、10.7 GHz、18.7 GHz、23.8 GHz、36.5 GHz 和 89 GHz）和两个极化状态（水平和垂直）上。本文使用的中国大陆区域 AMSR-E LST 数据由北京师范大学程洁教授团队提供。该团队综合考虑环境变量提出了一种经验反演算法<sup>[10]</sup>，利用国家冰雪数据中心 (<http://nsidc.org> [2020-09-27]) 的 AMSR-E 亮温产品生产了 LST 数据。其空间分辨率为 25 km，每日白天、夜晚过境成像两次，白天升轨成像，夜间降轨成像。由于本研究分季节进行模型训练，根据中国大陆气候特点，冬季一般跨越两个年份，因此，本文所使用的 AMSR-E 数据为 2010 年 1 月至 2011 年 2 月。

## 2.3 MODIS LST 数据

本研究使用的验证数据之一为 MODIS 每日 1 km 地表温度数据 (MYD11A1)，该数据的传感器同样搭载在 Aqua 卫星上。MODIS/Aqua 传感器与 AMSR-E 传感器位于同一平台上，具有相同的轨道几何结构和过境时间，因此无需考虑数据采集时间不一致问题。MYD11A1 可从美国国家航空航天局下载(<https://ladsweb.nascom.nasa.gov/search>)，该数据使用通用分裂窗算法反演生成。MYD11A1 由日常数据层组成，包括白天和夜间 LST 以及其他辅助数据，如质量控制 (QC) 层。第 6 版 MODIS LST 产品已在许多已发表的研究中得到验证，其质量总体优于先前版本<sup>[22]</sup>。

## 2.4 地面站点数据

选取黑河流域 (Heihe River Basin, HRB) 作为地面站点验证区域，对重建 LST 的准

确性进行评估。相应数据来源于黑河流域联合遥感监测实验研究（AWS-WATER，<http://www.heihedata.org/>）。该验证区是中国生态、水文和气候变化研究的重点关注区域，大量实验在该区域展开，积累了丰富的数据，在区域和全球尺度上对气候变化研究有着深刻的影响。AWS-WATER 由 12 个 HRB 的站点组成，每个站点每 30 分钟收集 5 厘米、10 厘米、20 厘米、40 厘米、80 厘米、120 厘米和 160 厘米深度的土壤温度。由于 5 厘米深度数据不完整，本研究选取花寨子(HZZ)沙漠站、大野口(DYK)关滩森林站和阿鲁(AR)冻融站每日 1:30、13:30 的 10 厘米土壤温度数据作为验证数据。

本研究使用相关数据基本情况如表 1 所示。

**表 1：本研究使用数据基本情况**

数据类型	空间分辨率	时间分辨率	坐标系统	时间跨度	用途
AMSR-E LST	25 km	0.5 天	-	2010.1-2011.2	训练、重建
MODIS LST	1 km	0.5 天	GCS_WGS_1984	2010 全年	验证
地面站点数据	-	30 分钟	-	2010.8-2010.12	验证

## 2.5 数据预处理

AMSR-E LST 数据、MYD11A1 数据像素值单位均为卡尔文 (K)，不需要进行转换。数据预处理主要包括 3 个步骤：(1) MYD11A1 像元质量控制；(2) MYD11A1 数据重采样；(3) AMSR-E LST 与 MYD11A1 数据配准。考虑 MODIS LST 产品质量问题，首先根据 MYD11A1 的质量控制文件，选取具有高精度的像元作为用于对比的候选像元(质量控制等级为：Mandatory QA flags=00、Data quality flag=00、Emis Error flag=00、LST LST Error flag=00)；由于 MYD11A1 数据与 AMSR-E LST 数据的空间分辨率不一致，将 MYD11A1 数据重采样到与 AMSR-E LST 数据相同的像元尺寸；调整两类数据的相对位置，使两类数据能够完全贴合，相同区域的像元一一对应。由于地面站点数据为土壤温度数据，与地表温度数据存在一定差异，为保持定量评价结果的原始性与可靠性，本文在 5.3 节中以 MYD11A1 数据为参考对土壤温度数据进行线性回归处理。

## 3 多时相地表温度数据样本集构建及优化

构建多时相地表温度数据样本集，首先需要根据 AMSR-E LST 的轨道间隙变化特点，考虑其周期性与互补性，选择合适的邻近时相组合。为使本文提出方法具有更好的推广性，本研究仅使用 AMSR-E LST 数据完成所有重建步骤，不使用其他数据作为辅助。因此地表温度样本标签的构建需要根据 AMSR-E LST 数据生成，即多时相地表温度数据样本集需要满足：(1) 样本数据对来自连续时相影像的相同位置；(2) 样本数据对均为完整数据（以获取样本标签）。在获取多时相数据对后，仍需进行模拟掩膜操作，使样本集与原始重建实验具有相同的数据特征。地表温度分布特点以及变化规律在不同季节、昼夜表现不同，为更好利用深度学习模型学习地表温度信息，将 2010 年 AMSR-E LST 数据按照四个季节、昼夜进行划分。具体划分方法如表 2。

表 2: 数据集划分表

白天		夜晚	
第 0 季度	1-2 月	第 0 季度	1-2 月
第 1 季度	3-5 月	第 1 季度	3-5 月
第 2 季度	6-8 月	第 2 季度	6-8 月
第 3 季度	9-11 月	第 3 季度	9-11 月
第 4 季度	12-2 月	第 4 季度	12-2 月

其中, 第 4 季度在训练过程中使用了 2011 年 1 月、2 月 AMSR-E LST 数据作为辅助, 以确保足够丰富的样本集。

### 3.1 轨道间隙时空分布特征分析

轨道间隙变化的周期为 16 天, 图 3 展示了一个变化周期内白天的轨道间隙分布情况。由于 AMSR-E 传感器白天升轨成像、夜晚降轨成像, 白天轨道间隙方向与夜晚轨道间隙方向呈现对称相反的特点。随着日期推移, 轨道间隙由东向西移动, 前后两日的轨道间隙位置偏移较大, T1 (第 1 日)、T3 (第 3 日) 的轨道间隙位置偏移微小, 因而邻近两日的轨道间隙呈互补的特点, 即 T2 (第 2 日) 的轨道间隙区域在 T1、T3 均为非轨道间隙区域。

基于 AMSE-E LST 轨道间隙邻近时相互补以及周期性变化的规律, 本文使用 24\*24 的窗口进行样本数据对的裁切, 进而利用 T1、T3 的原始像素重建 T2 对应位置的轨道间隙缺失像素 (如图 4 所示)。因而需要使用连续 3 日的 LST 样本数据对构建多时相地表温度数据样本集。

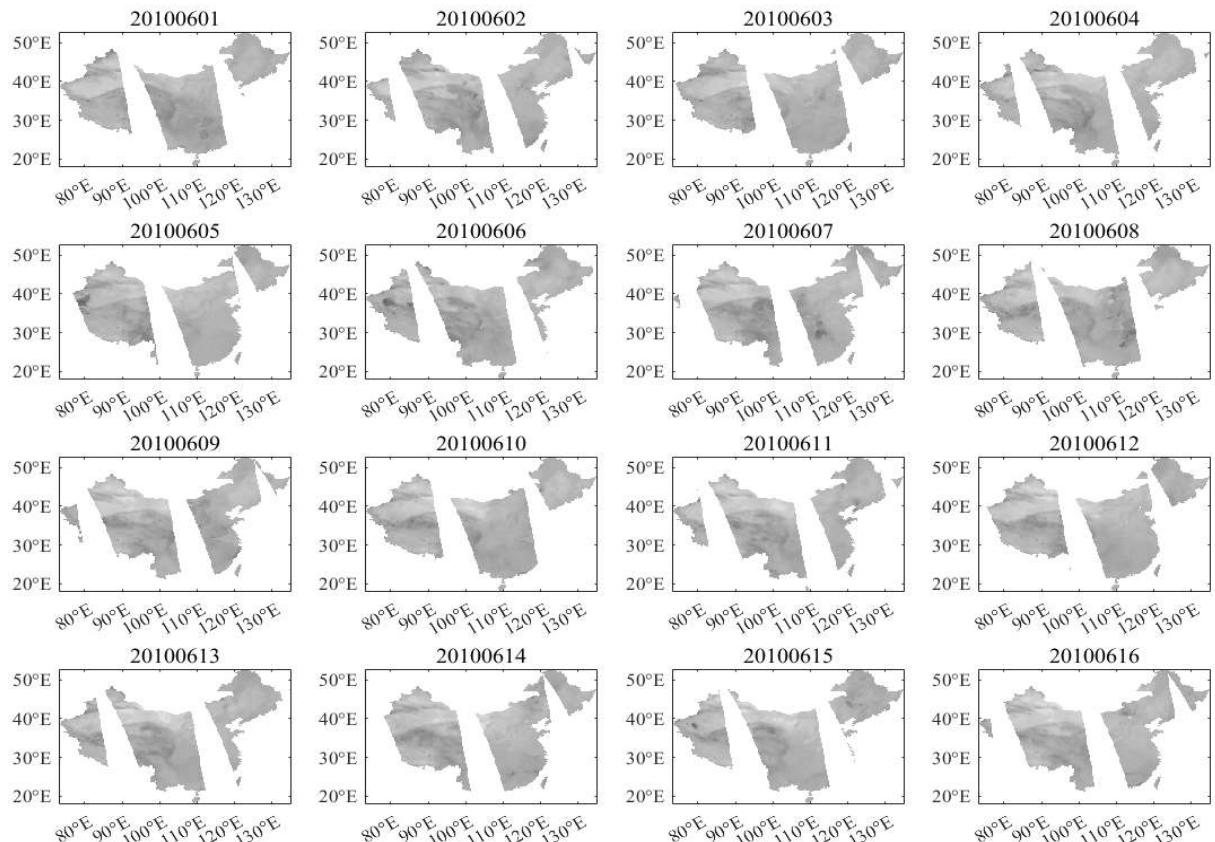


图 3: 白天轨道间隙周期变化示意图

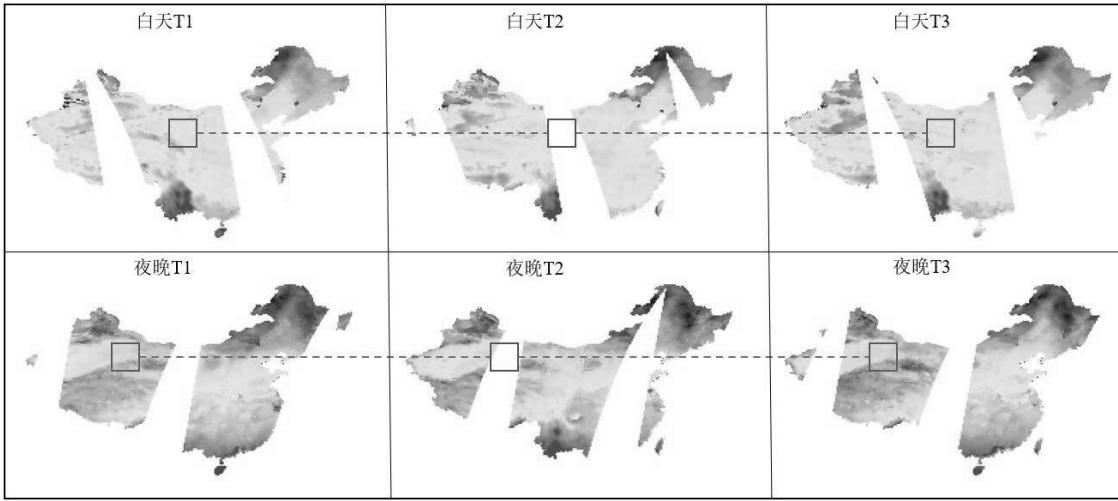


图 4: 连续三日的轨道间隙变化示意图

### 3.2 样本最邻近插值生成方法

AMSR-E LST 数据轨道间隙的周期性和邻近时相空间互补性特征，使得重建过程中模型充分利用了多时相的地表温度信息。然而其周期性和邻近时相空间互补性特征，以及训练时多时相地表温度样本集要求连续 3 日在相同位置都具有完整数据的特点，导致在样本集构建中难以获取丰富的样本数据对。AMSR-E LST 数据影像在中国大陆区域的尺寸大小为 248 像素\*143 像素，空间分辨率为 25 km。轨道间隙南北贯穿整个中国大陆区域，每幅影像具有 1-3 条轨道间隙（轨道中部宽度 30 像素左右），将中国大陆区域分割为至少 3 个部分，造成了 AMSR-E LST 中国大陆区域地表温度的不连续性。且由于轨道倾斜、邻近日期互补的特点，导致可供模型训练的样本量极少，且多来自中国大陆区域相同位置。使用连续 16 天的影像进行叠加，设置轨道缺失区域像素值为 0，原始区域的像素值为 1，相加形成图 5。数值越高，则表明该区域越多的影像具有原始的像素值，进而可以产生更多的样本对。相加结果显示大陆北部区域数值较大（轨道间隙由北向南逐渐变宽导致），即北部区域可产生较多的样本对，尤其是大陆东北区域；但越往南，可获得的样本对则越来越少。

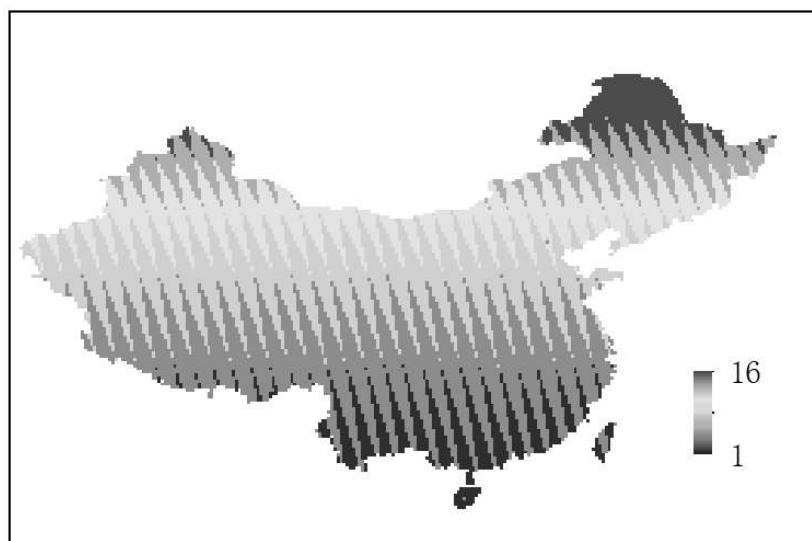


图 5: 连续 16 日 AMSR-E LST 影像叠加效果图

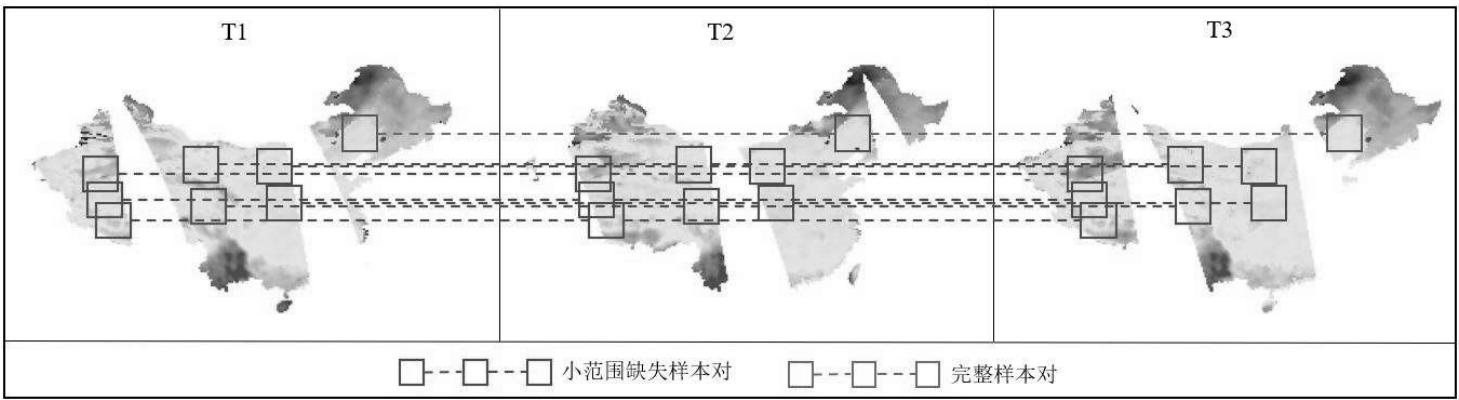


图 6：样本生成方式对比图

在 Wu 等人的重建方法中<sup>[23]</sup>，使用了连续 3 日相同位置且完整的数据对构建样本库。这导致可获得的完整样本对数量较少，且大量存在小范围轨道间隙的样本对被完全舍弃。然而被舍弃的、存在小范围轨道间隙的样本对可提供大量的、可供学习的样本特征。图 6 展示了完整样本对与存在小范围缺失样本对的样本数量、位置分布情况。

为克服这一缺陷，本文提出了一种样本最邻近插值生成方法，用于优化多时相样本集数量不足、特征不丰富的问题。具体方法如下：(1) 对原始 AMSR-E LST 影像按照一定角度进行旋转（实现多角度裁切，以丰富样本）以及水平翻转、竖直翻转的数据增强操作，并进行归一化；(2) 同时遍历裁切连续 3 日的影像（裁切尺寸 24\*24，滑动步长 4），若满足 3 幅影像块均完整，存入样本库；若满足 3 幅影像块原始像素占比均大于阈值  $m$ ，大陆区域外像素占比小于阈值  $n$ ，则对存在缺失的影像块进行最邻近插值处理，若插值结果满足一定阈值（影像块的最大值、最小值，以保证插值结果的合理性），则存入样本库。（经过多次实验确定的阈值  $m$  为 90%；阈值  $n$  为 0.9%，即 5 个像素。理论上  $m$ ,  $n$  随研究区域、空间分辨率以及裁切尺寸而变化，为方便计算，本文采用统一值）。

基于地理学第一定律，任何事物都有联系，相近的事物关联更紧密。一般来说，在时间邻近和空间邻近的条件下，温度的相关性越强，其变化越小<sup>[24]</sup>。对存在小范围缺失的裁切影像块进行插值，插值结果可近似代表原始结果，进而满足多时相地表温度样本集的样本生成要求，大大提升了对原始影像中各区域地表温度数据的利用。样本不但在数量上提升，所包含地表温度信息也得到进一步丰富。

### 3.3 单次循环模拟掩膜策略

本文待重建数据为轨道间隙位置的缺失数据，利用 T1、T3 原始区域像素以及 T2 部分原始像素重建 T2 缺失区域像素，最后拼接为完整的 AMSR-E LST 中国区域数据。上述样本集获得了连续 3 日完整的裁切影像块，为更加贴合原始重建情况，需要对 T2 的完整影像块进行模拟掩膜操作。通过对 T1、T2、T3 影像块的检查，不用于样本生成的影像块形成轨道掩膜库。轨道掩膜库中各种裁切影像块包含了轨道间隙的形状，且轨道间隙区域占比在一定范围内，具有一定的代表性。

在轨道掩膜库中，选取数幅更具有代表性的裁切影像块，制作为轨道间隙掩膜文件。要求模拟掩膜集中轨道掩膜形状分布均匀、具有较高的轨道间隙代表性。为保证在模型训

练过程中，加大对 T2 时刻部分原始像素信息的学习，采用单次循环掩膜的方式。具体方式为：(1) 遍历样本集中 T1、T2、T3 数据对；(2) 依次选取模拟掩膜集中单张掩膜；(3) 只对 T2 影像块进行掩膜处理，并输出掩膜结果，重新组成 T1、T2、T3、T2\_mask 数据对。

单次循环掩膜可保证样本集中每一组样本对 (T1<sub>k</sub>, T2<sub>k</sub>, T3<sub>k</sub>) 只具有一种轨道间隙，在模型训练的前向传播过程中，T2 影像块部分原始像素参与了模型训练；若对样本集进行多次循环掩膜（即每一组数据对具有多种轨道间隙，种类个数为模拟掩膜集中掩膜个数），在训练过程中，具有多种的轨道间隙形状的 T2 影像块在模型反向传播的过程中，T2 部分原始像素值的权重会被不断弱化，故失去对 T2 原始像素信息的利用，会导致重建结果与 T2 原始数据存在差异，形成新的“轨道”。

本文的多时相地表温度数据样本集构建步骤如图 7 所示。

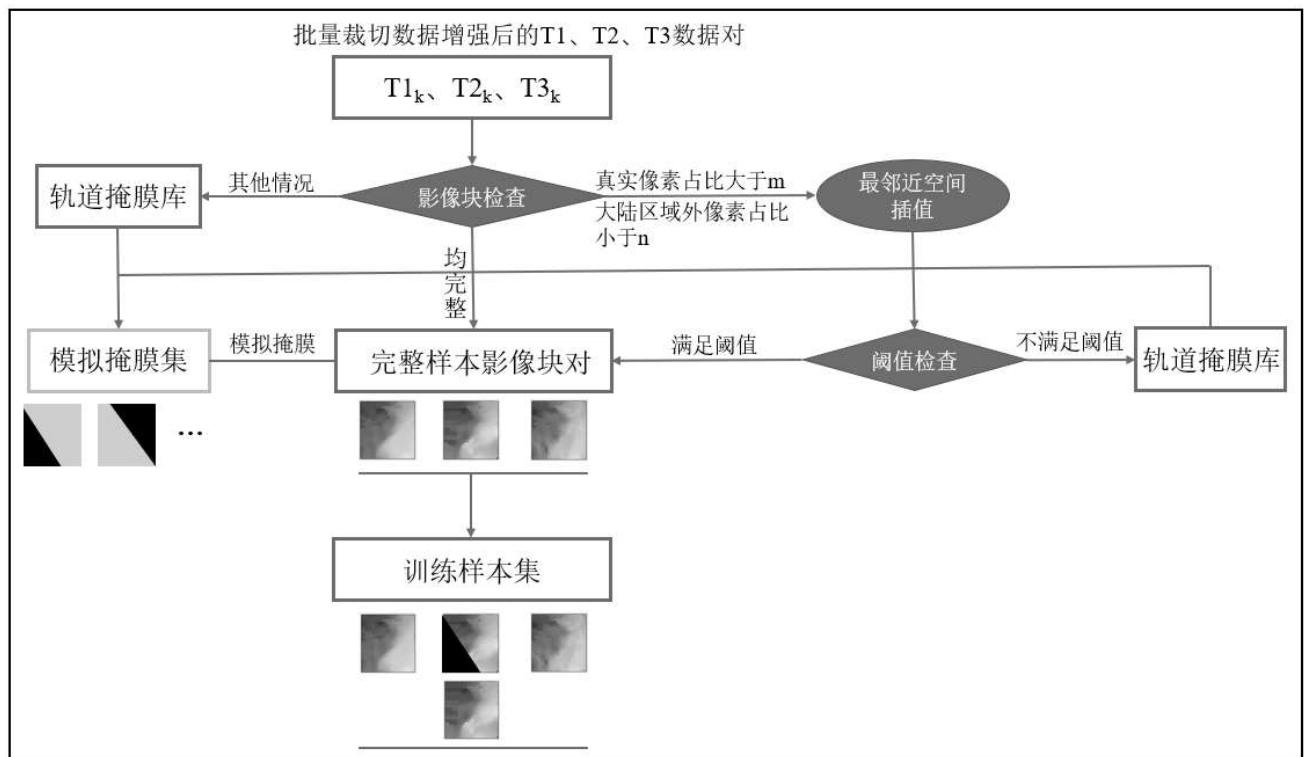


图 7：样本集生成流程图

## 4 模型构建与轨道间隙重建

### 4.1 深度学习网络模型构建及训练

#### 4.1.1 模型构建

卷积神经网络 (Convolutional Neural Network, CNN) 是深度学习方法中比较成熟的网络架构之一。CNN 卷积层和池化层交错的设置和局部感受野的特点，使其能够提取图像中更加抽象的特征<sup>[25]</sup>；并且 CNN 能够更好地提取多时相影像中隐藏的特征信息，并对其进行更深层次的学习<sup>[26]</sup>。针对中国大陆区域 AMSR-E LST 数据轨道间隙的时空分布特征，本文继续沿用了多时相特征连接的卷积神经网络 MTFC-CNN，主要包括上采样、下采样以及注意力单元三个部分，网络结构如图 8 所示，具体结构参数如表 3 所示。

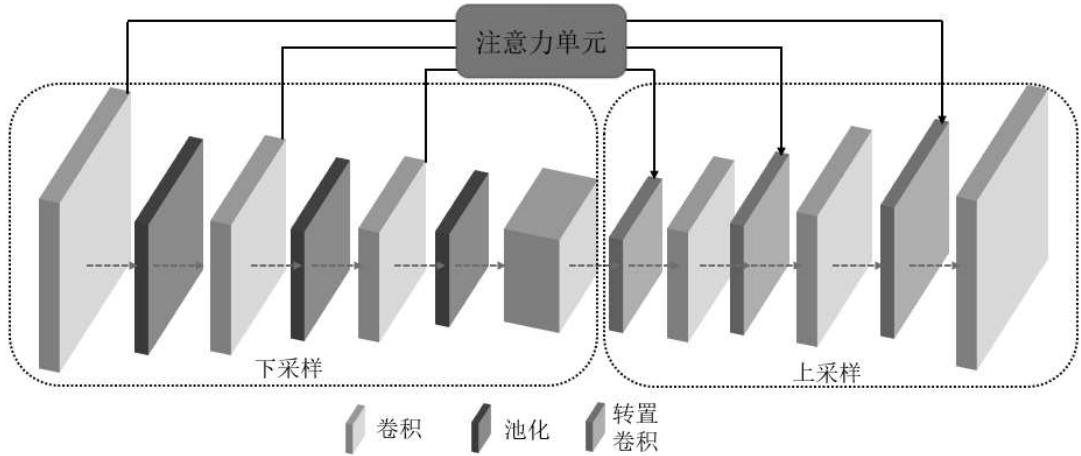


图 8：网络模型结构示意图

在下采样部分，主要结构特征如下：(1) 采用了四层卷积网络对 AMSR-E LST 数据进行信息特征提取，并在卷积层后添加批量归一化层（Batch Normalization, BN），确保各层间输入、输出具有相同的概率分布，以加快模型的收敛速度和参数拟合；(2) 激活函数选择 ReLU 函数（Rectified Linear Unit, ReLU），使各层间具有非线性的输入、输出关系，进而使模型学习多时相 LST 间的高动态性的非线性关系；(3) 为了使模型适合填充大间隙，有必要扩展卷积过程中的感知场。因此使用了卷积核大小为  $2*2$  的平均池化层（Average Pooling, AvgPool）扩展感受野，以增强多时相 LST 特征图上下文的信息。

在上采样部分，使用在特征还原上表现良好的转置卷积（Transposed Convolution, TransConv）来恢复特征图，实现 LST 从低分辨率到高分辨的映射。上采样与下采样保持了相同的结构，在卷积层中同样使用了 BN 和 ReLU。在最后一个卷积层中恢复特征图到与输入 LST 相同尺寸大小。

为了加大对空间信息的利用，避免 AMSR-E LST 的空间信息在下采样过程中丢失，模型中引入了一种空间注意力机制。采用一般的跳跃连接结构将低层特征与高层特征直接连接起来，会导致还原像素时由于引入了过多低层信息出现过拟合的现象。空间注意力机制与人类的选择性视觉注意力机制类似，其目标是从大量信息中选择出对当前任务更关键的信息。在注意力单元中，通过激活高层特征中的有效信息来输出低层特征信息的权重，提取到更为重要的位置信息，得到加权低层特征。上采样中再将高层特征和包含 LST 像素位置信息的加权低层特征相结合，作为卷积层的输入，增强获取不同 LST 空间信息的能力<sup>[23]</sup>。

表 3：模型结构参数表

	层数	卷积单元	尺寸变化
下采样	L1	{conv3*3,64,BN}*2 AvgPool 2*2	1
	L2	{conv3*3,128,BN}*2 AvgPool 2*2	1/2
	L3	{conv3*3,256,BN}*2 AvgPool 2*2	1/4
	L4	{conv3*3,512,BN}*2 AvgPool 2*2	1/8
上采样	L5	TransConv 2*2 {conv3*3,256,BN}*2	1/4
	L6	TransConv 2*2 {conv3*3,128,BN}*2	1/2
	L7	TransConv 2*2 {conv3*3,64,BN}*2; {conv3*3,32,BN;conv3*3,1}	1

#### 4.1.2 模型训练

模型训练过程如图 9 所示。在模型训练前，为有效利用各个时相 LST 的特征信息以及变化信息，需要对多时相数据进行组合处理。输入数据为 3 个时相 4 类数据：T1 完整影像块、T2 完整影像块（标签）、T3 完整影像块、T2 模拟掩膜影像块（待重建数据，由 T2 完整影像块模拟掩膜得到）。具体组合方式为：(1) 对 T1、T2 进行相加操作，对 T3、T2 进行相加操作；(2) 将两个相加结果在通道上连接，得到输入层（包括 5 层，T1、T2、T3、T1+T2、T2+T3 层）。

选择均方误差 MSE (Mean Square Error, MSE) 作为损失函数。MSE 是回归损失函数中最常用的误差，它是预测值  $f(x)$  与目标值  $y$  之间差值平方和的均值。MSE 函数的曲线光滑、连续并且处处可导，便于使用梯度下降算法，是一种常用的损失函数。随着误差的减小，梯度也在减小，有利于模型收敛。即使使用固定的学习率，也能较快的收敛到最小值。其计算公式如下式：

$$\text{Loss} = \frac{1}{m} \sum_{i=1}^m (X_i - Y_i)^2$$

式中， $X_i$ 、 $Y_i$  分别表示影像中第  $i$  个像素原始值和重建值， $m$  表示参与计算的像素个数。

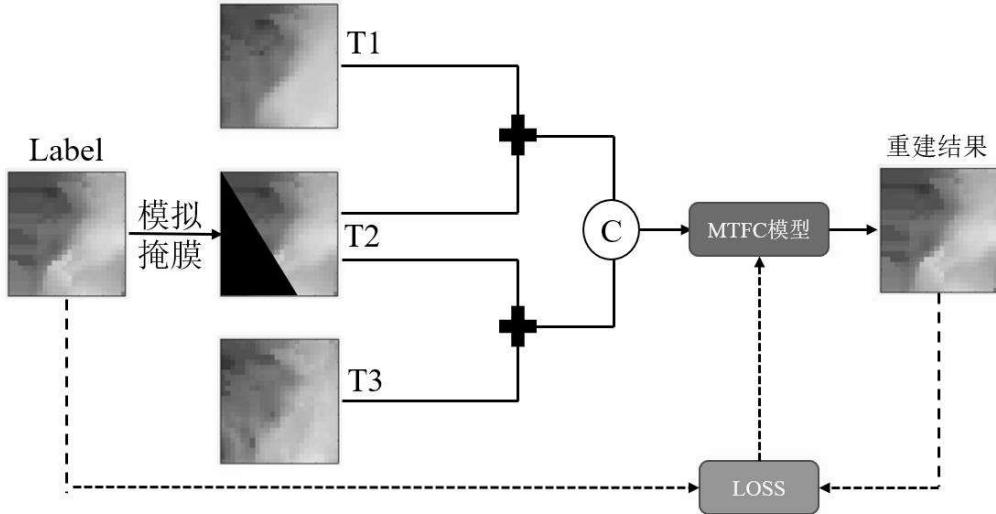


图 9：训练过程示意图

#### 4.2 轨道间隙区域批量重建

本文重建的数据为 2010 年全年昼夜的 AMSR-E LST 中国大陆区域数据，且重建每日数据需要该日前、后 2 天的数据作为模型输入，并且为了确保前、后两天数据的完整性(T1、T3 数据)需要进行最邻近空间插值操作。重建过程较为复杂，本文使用了一种批量重建的方法，如图 10 所示。条件裁切的方式可以快速生成模型输入层所需要的数据，T2 重建好的结果可作为下一轮重建的 T1 输入数据，大大减小了数据冗余，提升了重建速率。由于在裁切过程中使用了移动窗口裁切的方法，设置了滑动步长，因此在拼接过程中，采用平均权重的拼接方式。在相邻影像块重复的区域，像素值取重复区域像素的平均值，以提升重建结果的准确率。

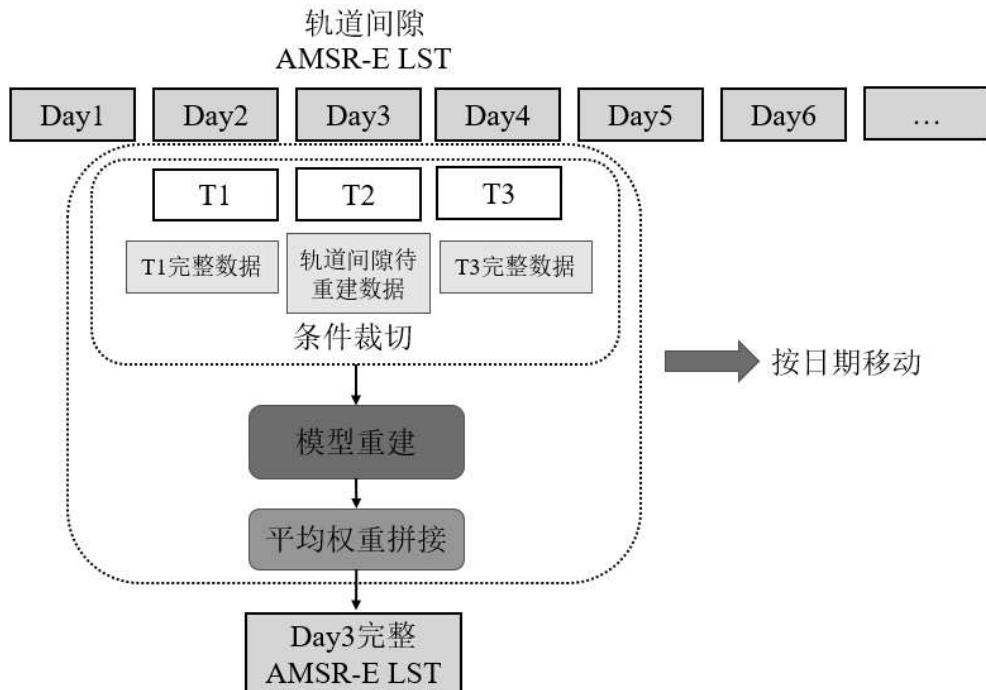


图 10：批量重建方法

## 5 结果分析

### 5.1 中国大陆区域重建结果

本文无缝重建了 2010 年全年昼夜的 AMSR-E LST 中国大陆区域数据。图 11(审图号: GS (2019) 1822 号) 展示了 2010 年各月份 15 日的白天和黑夜的中国大陆区域 AMSR-E LST 无缝重建结果。相对于原始区域, 重建区域的温度数值大小合理, 符合不同季节的中国大陆各区域的温度变化特点; 温度分布形状保持了相对连续性, 原始区域与重建区域过渡区域不存在明显的拼接痕迹。

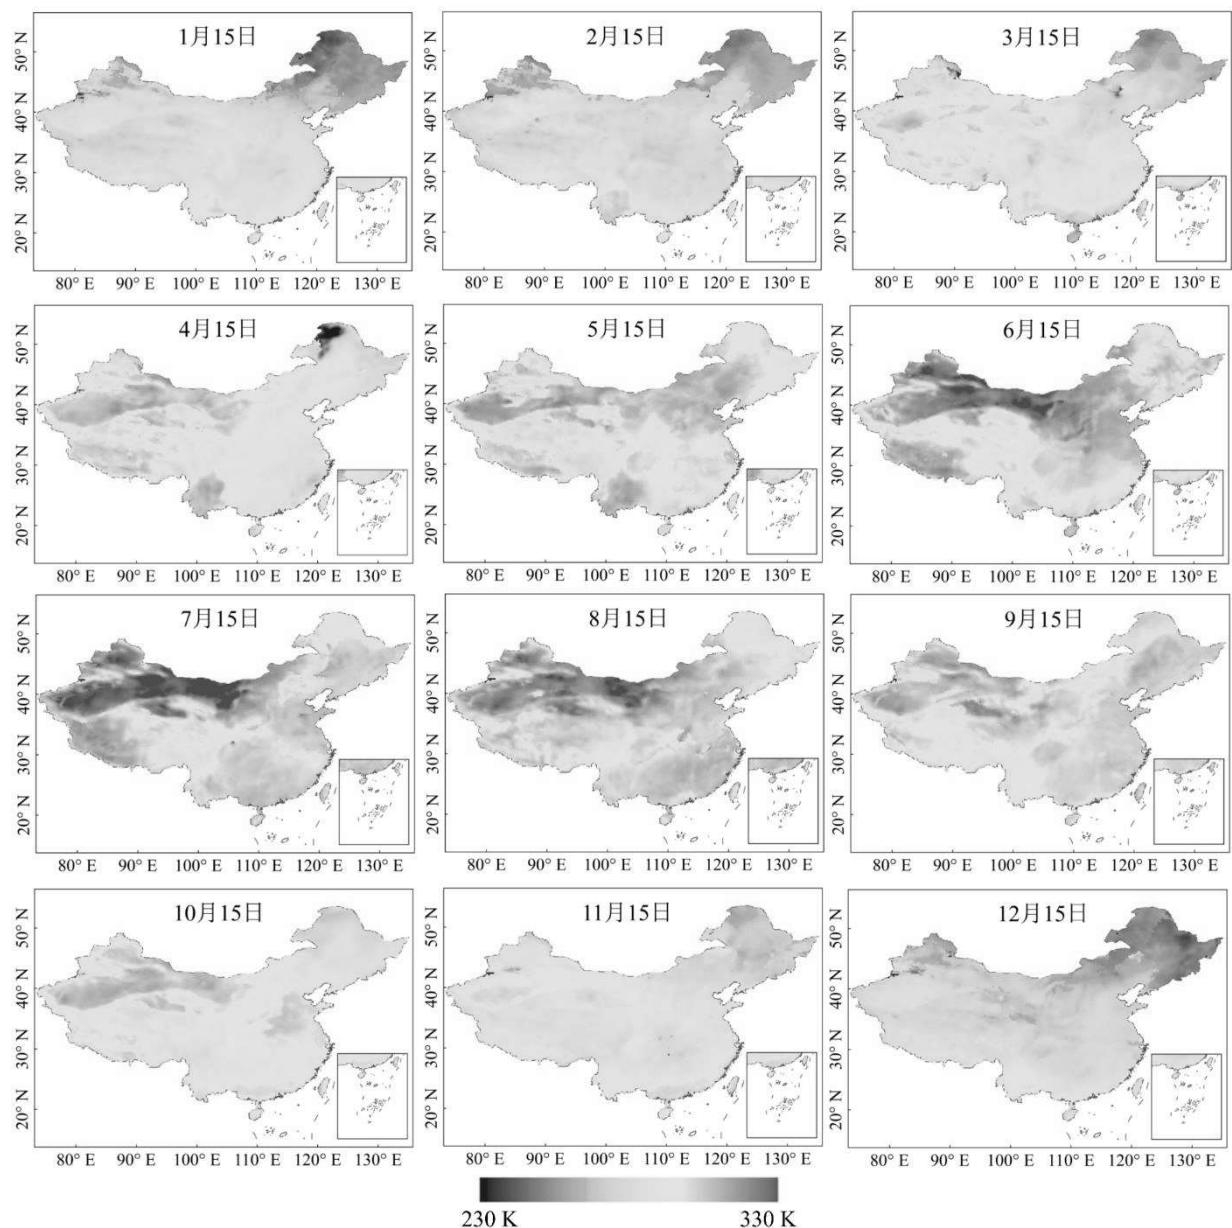


图 11-a: 每月 15 日白天中国大陆区域 AMSR-E LST 重建结果

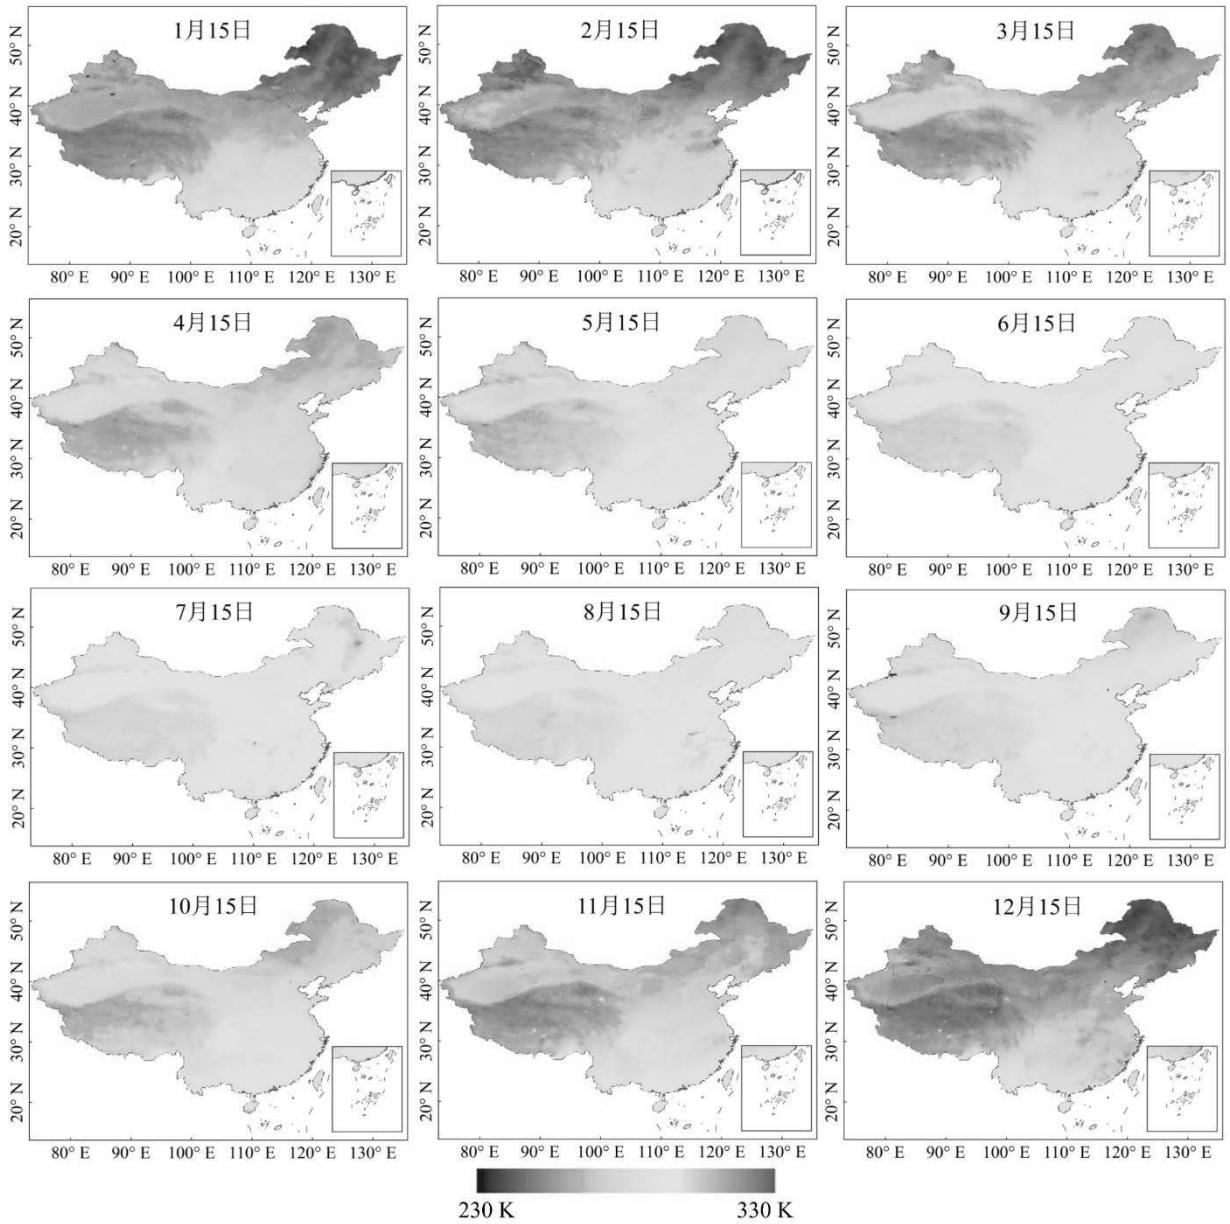


图 11-b: 每月 15 日夜晚中国陆地区域 AMSR-E LST 重建结果

## 5.2 MODIS LST 对比精度评价

使用对应日期的 MODIS LST 产品作为参考，检验本文重建结果的精度。对比分为两部分：(1) 重建轨道间隙区域精度对比；(2) 原始区域精度对比。分别计算 AMSR-E LST 重建区域像素、原始区域像素与 MODIS LST 产品对应区域的 RMSE。若重建区域 RMSE、原始区域 RMSE 二者接近，则说明轨道间隙区域的重建地表温度误差程度与原始区域近似，进一步验证了重建结果的真实性。

表 4: 2010 年每月 15 日与 MODIS LST 对比结果表

日期/月	1	2	3	4	5	6	7	8	9	10	11	12	整体 RMSE	整体 R <sup>2</sup>
原始区域	3.72	3.64	4.84	5.21	3.80	5.06	5.71	4.08	3.71	3.40	3.04	3.71	4.09	0.94
白天 重建区域	4.86	4.47	5.56	4.63	6.98	4.17	5.99	4.45	4.45	4.04	3.49	4.45	4.65	0.89
偏差	+1.14	+0.83	+0.72	-0.58	+3.18	-0.89	+0.28	+0.37	+0.74	+0.64	+0.45	+0.74	-0.56	+0.05
原始区域	3.18	3.00	3.13	2.41	2.73	2.36	2.22	1.89	2.05	2.01	2.35	3.18	2.58	0.97
夜晚 重建区域	3.05	3.29	2.99	2.81	3.38	3.22	3.40	1.97	2.78	2.41	2.37	5.34	3.28	0.92
偏差	+0.13	-0.29	+0.14	-0.40	-0.65	-0.86	-1.18	-0.08	-0.73	-0.40	-0.02	-2.16	-0.70	+0.05

表 4 为 2010 年每月 15 日 AMSR-E LST 完整数据与 MODIS LST 的对比表。其中 AMSR-E LST 重建区域与原始区域分别与 MODIS LST 的 RMSE 偏差在 0.7 K 以内,  $R^2$  偏差为 0.05。图 12 为白天、夜晚 AMSR-E LST 与 MODIS LST 的原始区域 (红色点)、重建区域 (蓝色点) 对比验证的散点图。红色点的横、纵坐标分别为 AMSR-E LST 原始区域某像素值以及对应相同位置 MODIS LST 的像素值; 蓝色点的横、纵坐标分别为 AMSR-E LST 重建区域某像素值以及对应相同位置 MODIS LST 的像素值。

从散点图的分布可以看出, 原始区域、重建区域散点均分布在对角线两侧, 说明了 MODIS LST 数据与 AMSR-E LST 数据较为贴合。且原始区域、重建区域的散点分布形状较为相似, 进一步说明了重建区域地表温度与未重建的原始区域地表温度具有较好的一致性。夜晚的定量评价结果均优于白天, 原因可能为夜晚的 LST 动态变化较小、规律性更强, 模型可以更好地利用温度变化规律, 因而夜晚重建结果精度更高。

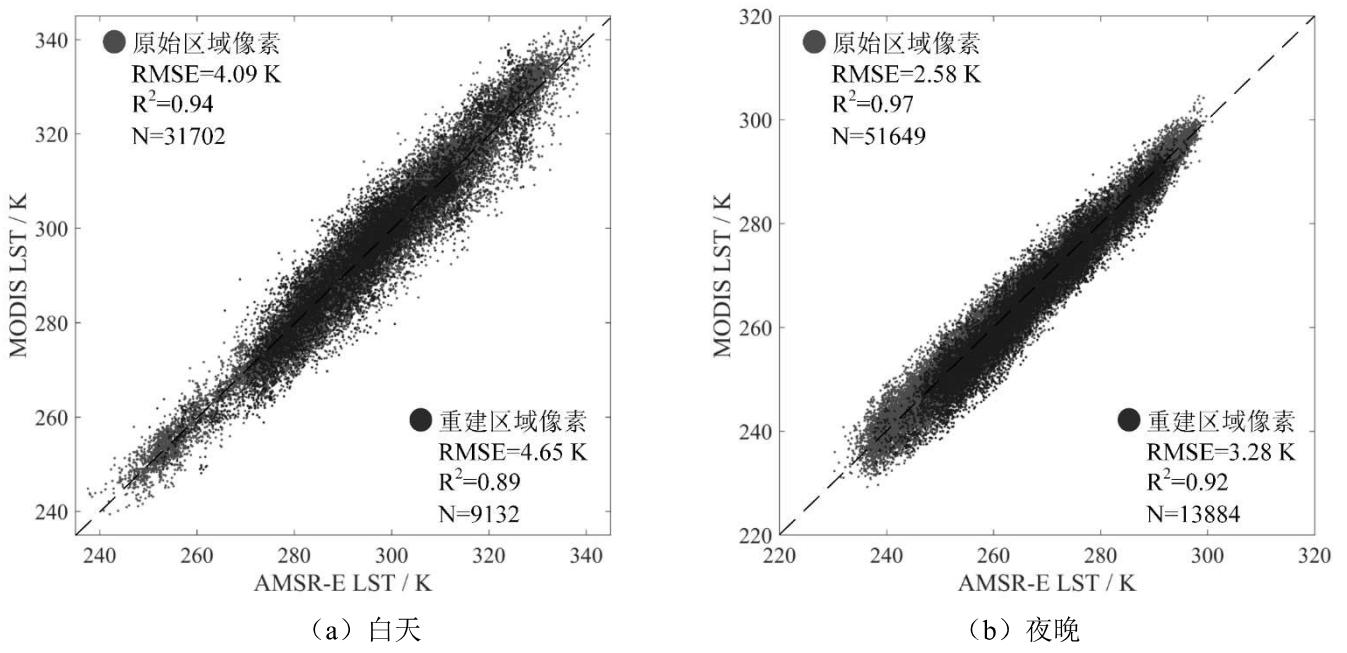


图 12: 重建 LST 和原始 LST 与 MODIS LST 对比情况散点图

### 5.3 站点数据精度评价

由于 MODIS LST 的局限性，只能评估晴空时重建精度。为了进一步评估无缝重建后的全天候 LST 数据，使用 2010 年黑河流域地区地面站点的土壤温度数据。本研究选取花寨子(HZZ)沙漠站、大野口(DYK)关滩森林站和阿鲁(AR)冻融站每日 1:30、13:30 的 10 厘米土壤温度数据作为验证数据。然而，实测地表温度与卫星观测地表温度在物理意义和空间尺度上存在差异，有必要在验证前对地表温度进行校准，使这两种类型的地表温度具有可比性<sup>[10]</sup>。首先将 MODIS LST 数据放大到 AMSR-E 数据的像元大小，然后使用最小二乘法建立 MODIS LST 与土壤温度之间的线性回归模型来调节土壤温度。HRB 站点提供 2010 年 8-12 月的土壤温度观测数据。三个验证站点的相关信息如表 5 所示(x 表示土壤温度，y 表示校正土壤温度后得到的地表温度)。

表 5：验证站点相关信息

名称	经度	纬度	高程	土地类型	线性回归模型
HZZ	E100° 19'06.9"	N38° 45'54.7"	1723m	沙漠草原	白天 $y=0.98x+14.77$ 夜晚 $y=0.87x+26.3$
DYK	E100°15'00.8"	N38°32'01.3"	2835m	阴坡森林	白天 $y=3.3x-612.86$ 夜晚 $y=2.14x-317.37$
AR	E100°27'52.9"	N38°02'39.8"	3032m	高山草甸	白天 $y=1.31x-77.6$ 夜晚 $y=1.24x-79.39$

如表 6 所示，分别计算了原始区域、重建区域与各站点数据间白天、黑夜的 RMSE 值。结果表明，各站点原始区域、重建区域 RMSE 的整体平均偏差为 0.52 K。大野口关滩森林站 (DYK) 位于黑河上游大野口子流域关滩阴坡的森林内，植被生长情况良好。植被覆盖因素使站点温度测量值与遥感观测值存在较大差异，因而 DYK 站点相对 HZZ、AR 站点的原始区域 RMSE、重建区域 RMSE 均较高。这表明地表覆盖类型也是影响地表温度空间分布的重要因素之一。夜晚期间原始区域、重建区域的 RMSE 均低于白天，可能原因是日照的变化。白天日照角度、方向不断变化，地表温度变化较大；夜晚温度较低，且变化较小。因而夜晚的重建区域精度评价结果优于白天，该规律与 5.2 节 MODIS LST 精度对比评价得出规律相同。

表 6：站点验证结果

昼夜类型	站点	原始区域	重建区域	偏差/K
		RMSE/K	RMSE/K	
白天	HZZ	4.58	3.81	+0.77
	DYK	7.08	6.12	+0.96
	AR	5.03	4.30	+0.73
夜晚	HZZ	2.68	2.90	-0.22
	DYK	2.93	3.34	-0.41
	AR	2.38	2.40	-0.02

#### 5.4 与原始 MTFC-CNN 结果对比

本文方法重建结果在目视效果、定量评价上均取得了较好的表现。Wu 等人同样使用深度学习的方法进行重建，因此重建结果与本文重建结果具有一定可比性。在样本集制作过程中，需要保证连续时相相同位置的影像块必须完整，因此 Wu 等人的重建结果受到样本集不均衡的影响较大，在部分样本量较少的日期重建结果较差。图 13 中选择了样本量较少情况下的重建结果进行对比，其中黑色虚线框标记了轨道缝隙的位置。Wu 等人的重建结果在样本不足情况下仍可观察到轨道间隙痕迹。本文相对而言实现了稳健的无缝重建，在 Wu 等人重建结果较差的情况下仍保持了良好的重建结果。为进一步评价，同样以 MODIS LST 作为参考，分别计算 Wu 等人结果、本文结果与 MODIS LST 对比的 RMSE、 $R^2$ 。表 7 为定量评价结果，本文重建的 2010 年全天候 AMSR-E LST 结果在白天 RMSE 相对提升 0.34 K， $R^2$  相对提升 0.01；在夜晚 RMSE 相对提升 0.16 K， $R^2$  相对提升 0.02。

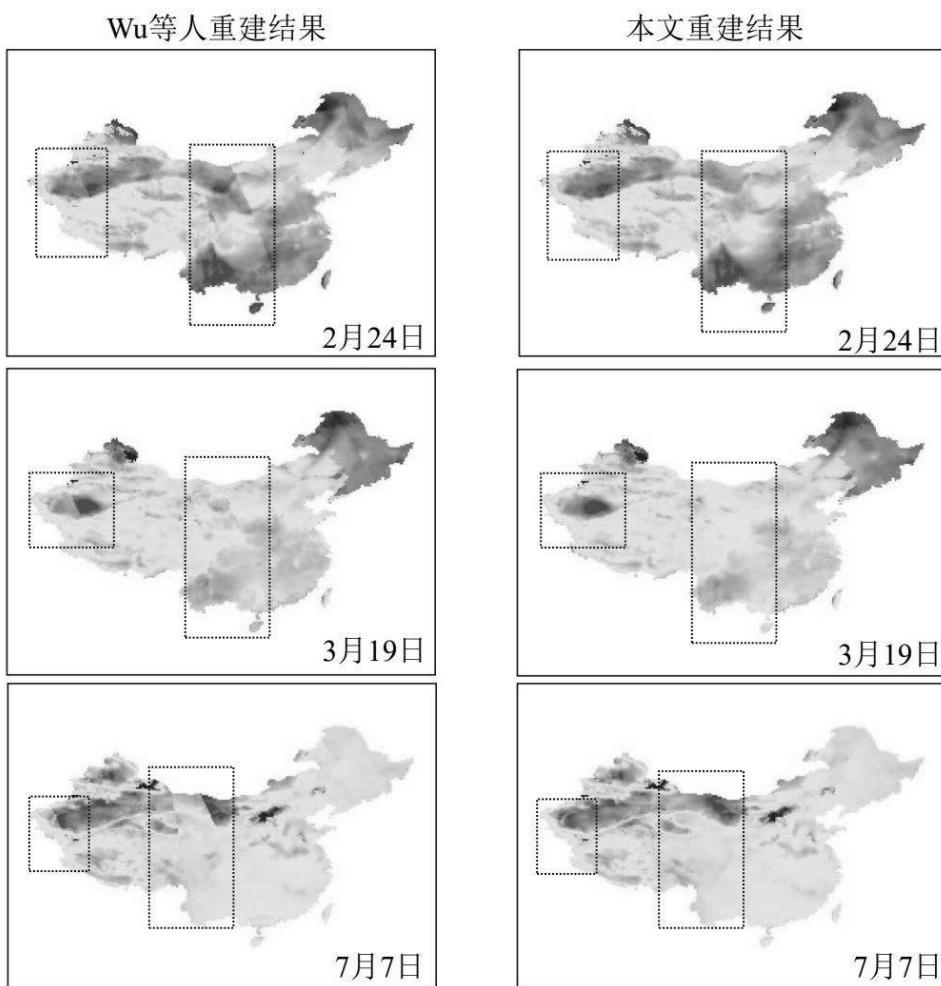


图 13：部分情况重建结果目视对比图

表 7: 2010 年 AMSR-E LST 重建结果对比精度评价表

数据类型		整体RMSE/K	整体R <sup>2</sup>
白天	原始区域	4.27	0.84
	Wu等人重建结果	5.42	0.65
	本文重建结果	5.08	0.66
	对比	+0.34	+0.01
夜晚	原始区域	3.11	0.92
	Wu等人重建结果	3.52	0.87
	本文重建结果	3.36	0.89
	对比	+0.16	+0.02

## 6 总结与展望

被动微波 AMSR-E LST 的轨道扫描间隙严重影响了该数据的空间完整性和连续性，因此无缝重建 AMSR-LST 数据具有重要意义。Wu 等人 MTFC-CNN 方法在样本数量较少、样本特征不够丰富时，重建结果存在明显的“有缝”痕迹。基于此，本文提出了一种样本优化的多时相特征连接卷积神经网络无缝重建方法 SO-MTFC，样本优化包括小范围缺失样本对插值生成方法和单次循环掩膜策略两个方面。以中国大陆区域为研究对象，按照昼夜、四季将数据划分为 10 个数据子集分别进行重建实验。实验结果表明：(1) 重建部分温度数值大小合理、与原始区域保持了良好的温度分布形状连续性，重建区域与原始区域基本实现无缝连接，取得了较好的目视效果；(2) 在以 MODIS LST 数据为参考的对比中，重建区域数据、原始区域数据保持了较为相近的定量评价结果，进一步证实了轨道间隙重建结果的真实性；(3) 通过地面站点数据的验证，原始区域、重建区域 RMSE 平均偏差为 0.52 K；(4) 相对于 Wu 等人的重建结果，以 MODIS LST 为参考本文结果在白天 RMSE 提升 0.34 K，在夜晚 RMSE 提升 0.16 K。故本文方法实现了稳健无缝重建的效果。

本文方法仅仅利用了 AMSR-E LST 数据进行轨道间隙重建，不需要任何辅助数据，因此本文方法具有一定的普适性和推广性，同样适用于其他具有轨道间隙缺失的被动微波数据，如 AMSR-2、MWRI 等，为具有扫描轨道间隙、多时相特点的遥感数据重建提供了思路。

然而，本文仍存在一些不足需要进一步深入研究。主要包括：(1) 多时相信息的深层次利用。实验表明在模型的输入层进行连接、组合等操作使得多时相信息能被有效利用，如何在模型中深层次融入多时相信息，进一步提高重建精度，是今后值得思考的突破点；(2) 体现异常变化的辅助数据引入。地表温度变化具有高动态性特点，部分日期可能出现温度突变的异常现象，本文按照季节、昼夜进行数据集划分并进行批量重建，不能处理多时相温度变化异常的情况。若可结合其他能够体现温度异常变化的辅助数据对处理异常情况，理论上整体重建精度可进一步提高。

## 主要参考文献

- [1] LI Z L, WU H, WANG N, et al. Land surface emissivity retrieval from satellite data[J]. International Journal of Remote Sensing, 2013, 34(9-10): 3084-3127.
- [2] HANSEN J, RUEDY R, SATO M, et al. GLOBAL SURFACE TEMPERATURE CHANGE[J]. Reviews of Geophysics, 2010, 48(4): RG4004.
- [3] 李召良, 段四波, 唐伯惠, 等. 热红外地表温度遥感反演方法研究进展[J]. 遥感学报, 2016, 20(5): 899-920.
- [4] LI Z L, TANG B H, HUA W, et al. Satellite-derived land surface temperature: Current status and perspectives[J]. Remote Sensing of Environment, 2013, 131: 14-37.
- [5] LI Z L, WU H, DUAN S B, et al. Satellite Remote Sensing of Global Land Surface Temperature: Definition, Methods, Products, and Applications[J]. Reviews of Geophysics, 2023, 61(1): e2022RG000777.
- [6] WU P H, YIN Z X, ZENG C, et al. Spatially continuous and high-resolution land surface temperature product generation: a review of reconstruction and spatiotemporal fusion techniques[J]. IEEE Geoscience and Remote Sensing Magazine, 2021, 9(3): 112-137.
- [7] LI X M, ZHOU Y Y, ASRAR G R, et al. Creating a seamless 1 km resolution daily land surface temperature dataset for urban and surrounding areas in the conterminous United States[J]. Remote Sensing of Environment, 2018, 206: 84-97.
- [8] TANG W, XUE D, LONG Z, et al. Near-Real-Time Estimation of 1-km All-weather Land Surface Temperature by Integrating Satellite Passive Microwave and Thermal Infrared Observations[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 1-5.
- [9] LONG D, YAN L, BAI L L, et al. Generation of MODIS-like land surface temperatures under all-weather conditions based on a data fusion approach[J]. Remote Sensing of Environment, 2020, 246: No.111863.
- [10] ZHANG Q, CHENG J. An empirical algorithm for retrieving land surface temperature from AMSR-E data considering the comprehensive effects of environmental variables[J]. Earth and Space Science, 2020.7(4): e2019EA001006.
- [11] HOMLES T R H, CROW W T, YILMAZ M T, et al. Enhancing model-based land surface temperature estimates using multiplatform microwave observations[J]. Journal of Geophysical Research: Atmospheres, 2013, 118(2): 577-591.
- [12] XU S, CHEN J. A new land surface temperature fusion strategy based on cumulative distribution function matching and multi-resolution Kalman filtering[J]. Remote Sensing of Environment, 2021, 254: No.112256
- [13] XU Y M, SHEN Y. Reconstruction of the land surface temperature time series using harmonic analysis[J]. Computers and Geosciences, 2013, 61: 126-132.
- [14] LIU Z H, WU P H, WU Y L, et al. Robust reconstruction of missing data in Feng Yun geostationary satellite land surface temperature products[J]. Journal of Remote Sensing, 2017, 21(1): 40-51.
- [15] ZHANG Q, YUAN Q Q, ZENG C, et al. Missing data reconstruction in remote sensing image with a unified spatial-temporal-spectral deep convolutional neural network[J]. IEEE Transactions on Geoscience and Remote Sensing, 2018, 56(8): 4274-4288.
- [16] LI B, LIANG S, LIU X, et al. Estimation of all-sky 1km land surface temperature over the conterminous United States[J]. Remote Sensing of Environment, 2021, 266: No.112707.

- [17] WEISS D J, ATKINSON P M, BHATT S, et al. An effective approach for gap-filling continental scale remotely sensed time-series[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2014, 98: 106-118.
- [18] DUAN S B, LI Z L, LENG P. A framework for the retrieval of all-weather land surface temperature at a high spatial resolution from polar-orbiting thermal infrared and passive microwave data[J]. Remote Sensing of Environment, 2017, 195: 107-117.
- [19] GAO Z, HOU Y, ZAITCHIK B F, et al. A two-step integrated MLP-GTWR method to estimate 1 km land surface temperature with complete spatial coverage in humid, cloudy regions[J]. Remote Sensing, 2021, 13(5): No.971.
- [20] ZHANG X D, ZHOU J, LIANG S L, et al. Estimation of 1-km all-weather remotely sensed land surface temperature based on reconstructed spatial-seamless satellite passive microwave brightness temperature and thermal infrared data[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2020, 167: 321-344.
- [21] LIAN Y, DUAN S B, HUANG C, et al . Generation of Spatial-Seamless AMSR2 Land Surface Temperature in China During 2012–2020 Using a Deep Neural Network[J], IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-18.
- [22] WU P H, SU Y, DUAN S B, et al. A two-step deep learning framework for mapping gapless all-weather land surface temperature using thermal infrared and passive microwave data[J]. Remote Sensing of Environment, 2022, (277): No.113070.
- [23] 苏扬, 吴鹏海, 程洁, 等. AMSR-E 地表温度数据重建深度学习方法[J]. 遥感学报, 2022, 26(4): 739-751.
- [24] 李小文, 曹春香, 常超一. 地理学第一定律与时空邻近度的提出[J]. 自然杂志, 2007(2): 69-71.
- [25] 牛鑫鑫, 孙阿猛, 王钎沣, 等. 基于深度学习的遥感图像分类研究[J]. 激光杂志, 2021, 42(5): 10-14.
- [26] 董蕴雅, 张倩. 基于 CNN 的高分遥感影像深度语义特征提取研究综述[J]. 遥感技术与应用, 2019, 34(1): 1-11.